



AeroTrack

Monitoramento de qualidade do ar com Apache Hop

Monitoramento de Qualidade do Ar com Apache Hop

Trabalho Final | Modulo 6 | Apache Hop

Allef Oliveira Ramos · Fernanda de Oliveira da Costa · Juliana Ballin Lima · Pedro Henrique Oliveira Dias



Agenda da apresentacao

- Contexto, dataset e problema
- Arquitetura da solucao
- Pipelines e workflow no Apache Hop
- Tratamento de dados
- Banco de dados e estrategia de reexecucao
- Indicadores e dashboard
- Validacao dos resultados
- Conclusao



Dataset e problema principal

- Dataset: Air Quality, UCI Machine Learning Repository
- Origem: estacao de monitoramento em uma cidade italiana (De Vito et al.)
- Periodo: marco de 2004 a fevereiro de 2005
- Volume: 9357 leituras horarias, 15 variaveis

PROBLEMA

Em quais periodos ocorreram as piores condicoes de qualidade do ar registradas, e quais variaveis ambientais estavam associadas a esses periodos?



Arquitetura da solucao



Duas pipelines Apache Hop (pl_01_ingestao_tratamento e pl_02_consolidacao_indicadores), orquestradas pelo workflow wf_orquestracao_qualidade_ar, que so avanca para a consolidacao apos o sucesso da ingestao.



Pipeline de ingestao e tratamento

- CSV Input le o dataset bruto (separador ponto e virgula, decimal com virgula)
- Filter Rows remove as linhas vazias deixadas pelo export do dataset
- Formula combina data e hora em um texto unico; Null If trata o valor -200 (ausencia de leitura)
- Select Values renomeia os campos e converte o texto de data para o tipo Data
- Calculator, Value Mapper e Number Range derivam ano, mes, turno e o nivel de CO e de NO2
- Janino calcula se a leitura e valida; Filter Rows separa leituras validas das rejeitadas
- Insert/Update grava no PostgreSQL, com chave em data_hora (sem duplicar em reexecucoes)



Pipeline de consolidacao e workflow

pl_02_consolidacao_indicadores

- Table Input agrega as leituras tratadas por dia e por mes
- Insert/Update grava os resumos em resumo_diario_qualidade_ar e resumo_mensal_qualidade_ar

wf_orquestracao_qualidade_ar

START → Ingestao e tratamento → Consolidacao de indicadores → Processo concluido



Tratamentos aplicados

- Valor sentinela -200: convertido em nulo antes de qualquer calculo (Null If)
- 114 linhas vazias do export do dataset: descartadas na ingestao (Filter Rows)
- Leituras sem nenhum poluente de referencia (CO, NOx e NO2): separadas em leituras_rejeitadas
- Classificacao analitica de CO e de NO2 (BOM, MODERADO, CRITICO): calculada a partir dos percentis reais do dataset, sem referencia a norma regulatoria externa



Banco de dados e reexecucao

`leituras_qualidade_ar`

Dados tratados e detalhados, uma linha por leitura valida

`leituras_rejeitadas`

Leituras sem poluente de referencia

`resumo_diario_qualidade_ar`

Indicadores agregados por dia

`resumo_mensal_qualidade_ar`

Indicadores agregados por mes

Reexecucao sem duplicidade

Chave UNIQUE em data_hora e carga por Insert/Update: reexecutar o processo atualiza os registros existentes em vez de duplicar. Validado executando o workflow duas vezes seguidas (8131 linhas nas duas execucoes).



Indicadores calculados

- Total de leituras tratadas e rejeitadas
- Percentual de horas em condicao critica
- CO e NO2 medios e maximos do periodo
- Evolucao mensal de CO e de NO2
- Distribuicao das leituras por nivel (BOM, MODERADO, CRITICO)
- Leituras por turno do dia
- Ranking dos dez dias com piores condicoes



Dashboard AeroTrack



AeroTrack

Monitoramento de qualidade do ar · leituras horarias tratadas pelo Apache Hop

Indicadores gerados em 17/08/2026, 16:05:04

LEITURAS TRATADAS

8.131

REGISTROS REJEITADOS

1.226

sem leitura de CO, NOx
e NO2

% HORAS EM
CONDICAO CRITICA

13.11%

CO MEDIO (MG/M3)

2.15

maximo 11.9

NO2 MEDIO (UG/M3)

113.09

maximo 340

TEMPERATURA MEDIA

17.97 °C


UMIDADE RELATIVA
MEDIA

48.95%


Evolucao mensal

Media mensal de CO e de NO2 nas leituras tratadas (cada poluente em sua propria escala).

CO medio (mg/m3)



NO2 medio (ug/m3)





Ranking dos dez piores dias

Ranking dos 10 dias com piores condicoes

Dias ordenados pela maior media diaria de CO, com media de NO2 e percentual de horas em condicao critica.

DATA	CO MEDIO	NO2 MEDIO	HORAS CRITICAS	% HORAS CRITICAS
19/10/2004	5.65	139.75	6	75%
23/12/2004	5.32	166.52	17	70.83%
22/11/2004	5.06	163	15	62.5%
25/11/2004	4.64	159.74	13	54.17%
15/12/2004	4.43	162.96	13	54.17%
01/11/2004	4.33	102.22	11	45.83%
14/04/2004	4.19	130.53	5	33.33%
06/10/2004	4.19	98.38	4	50%
10/02/2005	4.16	223.35	16	66.67%
22/12/2004	4.06	172.09	10	41.67%



Validacao dos resultados

LEITURAS TRATADAS

8.131

LEITURAS REJEITADAS

1.226

% HORAS CRITICAS

13,11%

CO MEDIO

2,15 mg/m3

NO2 MEDIO

113,09 ug/m3

DIAS CONSOLIDADOS

363

A soma de leituras validas e rejeitadas confere com o total de linhas de dados apos a remocao das 114 linhas vazias do export. O ranking dos piores dias mostra media de NO2 e percentual de horas criticas elevados nas mesmas datas de maior media de CO.



Conclusao

- O AeroTrack cobre o ciclo completo do trabalho final: ingestao, tratamento real dentro do Apache Hop, persistencia reexecutavel, orquestracao por workflow e indicadores em dashboard
- A classificacao de CO e NO2 foi calibrada pelos percentis reais do dataset, tornando o indicador de horas criticas informativo
- A etapa mais trabalhosa foi garantir que cada transformacao gravasse exatamente os campos esperados, validado executando a pipeline real contra o banco de dados a cada ajuste

Equipe AeroTrack

Juliana Ballin Lima

@JulianaBallin

Allef Oliveira Ramos

@allef-oliveira

Fernanda de Oliveira da Costa

@nanda-costa

Pedro Henrique Oliveira Dias

@pedroddias-oss

Obrigado