



AeroTrack

Air quality monitoring with Apache Hop

Monitoramento de Qualidade do Ar com Apache Hop

Trabalho Final do Módulo 6 | Apache Hop

Allef Oliveira Ramos · Fernanda de Oliveira da Costa · Juliana Ballin Lima · Pedro Henrique Oliveira Dias



Você não consegue ver o ar que respira.

A poluição do ar é um dos maiores riscos ambientais à saúde no mundo.

Os níveis de CO e NO2 podem disparar por horas sem que ninguém perceba, até que a exposição já tenha acontecido.

A pergunta real não é “o ar está poluído”. É: exatamente QUANDO ele esteve pior, e quais condições contribuíram para isso?

Sem dados tratados, essa pergunta não tem resposta



Ruído do sensor bruto

Leituras ausentes, um valor sentinela - 200 e linhas vazias do export escondem o sinal real.



Sem estrutura

Nada indica quais horas, dias ou meses foram realmente críticos.



Sem memória

Sem um banco de dados, toda análise recomeça do zero, sempre.

O AeroTrack foi criado exatamente para preencher essa lacuna.



Do dado bruto do sensor a uma resposta clara e confiável.

Construído de ponta a ponta com Apache Hop



Dataset e problema

- Dataset: Air Quality, UCI Machine Learning Repository
- Origem: estação de monitoramento em uma cidade italiana (De Vito et al.)
- Período: março de 2004 a fevereiro de 2005
- Volume: 9357 leituras horárias, 15 variáveis

PROBLEMA

Em quais períodos ocorreram as piores condições de qualidade do ar, e quais variáveis ambientais estavam associadas a esses períodos?



Arquitetura de ponta a ponta



Duas pipelines Apache Hop, orquestradas por um workflow: `pl_01_ingestion_treatment` e `pl_02_indicator_consolidation`, alimentando um banco PostgreSQL e um dashboard.



Pipeline de ingestão e tratamento

- CSV Input lê o dataset bruto (separador ponto e vírgula, decimal com vírgula)
- Filter Rows remove as linhas vazias deixadas pelo export do dataset
- Formula monta um único texto de data e hora; Null If trata o sentinela -200
- Select Values renomeia os campos e converte o texto em um tipo Data
- Calculator, Value Mapper e Number Range derivam ano, mês, turno e o nível de CO/NO2
- Janino calcula se a leitura é válida; Filter Rows separa leituras válidas das rejeitadas
- Insert/Update grava no PostgreSQL com chave em data_hora, seguro para reexecutar



Pipeline de consolidação e orquestração

pl_02_indicator_consolidation

- Table Input agrega as leituras tratadas por dia e por mês
- Insert/Update grava resumo_diario_qualidade_ar e resumo_mensal_qualidade_ar

wf_air_quality_orchestration

START → Ingestão e tratamento → Consolidação de indicadores → Processo concluído

O segundo hop só é seguido se a ingestão terminar com sucesso, evitando consolidar indicadores a partir de uma carga incompleta.



Tratamentos aplicados

- Sentinela -200: convertido em nulo antes de qualquer cálculo (Null If)
- 114 linhas vazias do export: descartadas na ingestão (Filter Rows)
- Leituras sem nenhum poluente de referência (CO, NOx e NO2): separadas em leituras_rejeitadas
- Classificação analítica de CO e NO2 (BOM, MODERADO, CRÍTICO): calibrada pelos percentis do próprio dataset, sem referência regulatória externa
- Correção de limite: a faixa NOITE excluía a hora 23 até ser ampliada para incluí-la



Banco de dados e segurança de reexecução

`leituras_qualidade_ar`

Dados tratados e detalhados, uma linha por leitura válida

`leituras_rejeitadas`

Leituras sem nenhum poluente de referência

`resumo_diario_qualidade_ar`

Indicadores agregados por dia

`resumo_mensal_qualidade_ar`

Indicadores agregados por mês

Reexecução sem duplicidade

Chave UNIQUE em data_hora mais Insert/Update: reexecutar o processo atualiza os registros existentes em vez de duplicar. Validado executando o workflow duas vezes seguidas (8131 linhas nas duas execuções).



Demonstração ao vivo

Agora, direto no Apache Hop Designer

- Abertura do projeto aerotrack no Hop Designer
- Canvas de pl_01_ingestion_treatment: ingestão, tratamento e classificação
- Canvas de pl_02_indicator_consolidation: resumos diário e mensal
- Execução de wf_air_quality_orchestration de ponta a ponta, ao vivo
- Conferência do resultado direto no PostgreSQL




Indicadores calculados

- Total de leituras tratadas e rejeitadas
- Percentual de horas em condição crítica
- CO e NO2 médios e máximos
- Evolução mensal de CO e de NO2
- Distribuição das leituras por nível (bom, moderado, crítico)
- Leituras por turno do dia
- Ranking dos dez piores dias



Dashboard AeroTrack





Ranking dos dez piores dias

Ranking of the 10 worst days

Days sorted by the highest daily average CO, with average NO2 and percentage of hours in critical condition. Click a column to sort, or use the search box above.

DATE ▾	AVG. CO ▾	AVG. NO2 ▾	CRITICAL HOURS ▾	% CRITICAL HOURS ▾
10/19/2004	5.65	139.75	6	■ 75%
12/23/2004	5.32	166.52	17	■ 70.83%
11/22/2004	5.06	163	15	■ 62.5%
11/25/2004	4.64	159.74	13	■ 54.17%
12/15/2004	4.43	162.96	13	■ 54.17%
11/1/2004	4.33	102.22	11	■ 45.83%
4/14/2004	4.19	130.53	5	■ 33.33%
10/6/2004	4.19	98.38	4	■ 50%
2/10/2005	4.16	223.35	16	■ 66.67%
12/22/2004	4.06	172.09	10	■ 41.67%



Validação dos resultados

LEITURAS TRATADAS

8.131

REGISTROS REJEITADOS

1.226

% HORAS CRÍTICAS

13,11%

CO MÉDIO

2,15 mg/m3

NO2 MÉDIO

113,09 ug/m3

DIAS CONSOLIDADOS

363


Leituras válidas mais rejeitadas batem com o total do dataset após remover as 114 linhas vazias do export. O ranking dos piores dias mostra NO2 e percentual de horas críticas elevados nas mesmas datas de maior CO, consistente com o comportamento real dos poluentes.

Toda hora crítica agora tem um registro

- O AeroTrack transforma exports brutos e ruidosos em um banco capaz de responder, com evidência, quando a qualidade do ar foi pior
- A classificação de CO/NO2 foi calibrada pela distribuição real do dataset, não por limites arbitrários
- Toda tabela é segura para recarregar: Insert/Update garante nenhuma duplicidade, execução após execução



Relatório de desenvolvimento



Capa

Relatório de Desenvolvimento		AeroTrack
Sumário		
Identificação do documento		i
Resumo executivo		ii
1 Contexto, objetivo e problema		1
1.1 Contexto acadêmico		1
1.2 Objetivo geral		1
1.3 Dataset utilizado		1
1.4 Problema principal		2
2 Arquitetura da solução		3
2.1 Visão geral		3
2.2 Tecnologias utilizadas		3
3 Pipelines Apache Hop		4
3.1 pl_01_ingestion_treatment		4
3.2 pl_02_indicator_consolidation		5
3.3 Workflow de orquestração		6
4 Tratamento de dados		7
4.1 Valor sentinela -200		7
4.2 Linhas vazias do export		7
4.3 Separação de leituras inválidas		7
4.4 Classificação analítica		7
5 Banco de dados		8
Módulo 6 Apache Hop	Página iii de 17	AeroTrack Versão 1.0

Sumário

23 PÁGINAS

- Arquitetura, pipelines e workflow em detalhe
- Tratamento de dados e ajustes técnicos
- Contrato do banco de dados
- Indicadores, dashboard e validação dos resultados
- Manual de replicação passo a passo

<docs/evidencias/relatorio-desenvolvimento-aerotrack.pdf>

Equipe AeroTrack

Juliana Ballin Lima

@JulianaBallin

Allef Oliveira Ramos

@allef-oliveira

Fernanda de Oliveira da Costa

@nanda-costa

Pedro Henrique Oliveira Dias

@pedroddias-oss

Obrigado