



AeroTrack

Monitoramento de qualidade do ar com Apache Hop

RELATORIO DE DESENVOLVIMENTO

Monitoramento de Qualidade do Ar com Apache Hop

Trabalho Final | Modulo 6 | Apache Hop

Equipe AeroTrack

Allef Oliveira Ramos	@allef-oliveira
Fernanda de Oliveira da Costa	@nanda-costa
Juliana Ballin Lima	@JulianaBallin
Pedro Henrique Oliveira Dias	@pedroddias-oss

Manaus | 2026

Capacitacao em IA e Transformacao Digital



Identificacao do documento

Projeto	AeroTrack
Documento	Relatorio de Desenvolvimento
Curso	Capacitacao em IA e Transformacao Digital
Modulo	Modulo 6 de Apache Hop
Projeto sugerido	Projeto 4, Monitoramento de Qualidade do Ar
Repositorio	https://github.com/JulianaBallin/AeroTrack
Branch de desenvolvimento	develop
Versao	1.0
Situacao	Pipelines, workflow, banco de dados e dashboard validados de ponta a ponta

Controle de revisao

Este documento registra o problema, a arquitetura, as pipelines, o tratamento de dados, o banco de dados, os indicadores, o dashboard e a validacao dos resultados do AeroTrack. Todas as execucoes descritas foram realizadas contra o banco de dados real, via linha de comando do Apache Hop.



Resumo executivo

O AeroTrack é uma solução de integração de dados construída com Apache Hop para o Projeto 4 sugerido no trabalho final do Módulo 6: monitoramento de qualidade do ar. O dataset público Air Quality (UCI Machine Learning Repository) é lido, tratado, classificado e persistido em um banco de dados PostgreSQL, com indicadores consolidados e apresentados em um dashboard.

Resultado técnico atual

- Duas pipelines Apache Hop (ingestão/tratamento e consolidação) e um workflow de orquestração, executados de ponta a ponta sem erros.
- 9357 leituras horárias processadas: 8131 gravadas como válidas e 1226 separadas por não terem nenhum poluente de referência.
- Banco de dados PostgreSQL com quatro tabelas e duas visões, reexecutável sem duplicidade por chave única e Insert/Update.
- Indicadores diários (363 dias) e mensais (14 meses) consolidados.
- Dashboard estático com sete indicadores, quatro gráficos e o ranking dos dez piores dias.



Sumário

Identificacao do documento	i
Resumo executivo	ii
1 Contexto, objetivo e problema	1
1.1 Contexto academico	1
1.2 Objetivo geral	1
1.3 Dataset utilizado	1
1.4 Problema principal	2
2 Arquitetura da solucao	3
2.1 Visao geral	3
2.2 Tecnologias utilizadas	3
3 Pipelines Apache Hop	4
3.1 pl_01_ingestao_tratamento	4
3.2 pl_02_consolidacao_indicadores	5
3.3 Workflow de orquestracao	6
4 Tratamento de dados	7
4.1 Valor sentinela -200	7
4.2 Linhas vazias do export	7
4.3 Separacao de leituras invalidas	7
4.4 Classificacao analitica	7
5 Banco de dados	8



5.1	Estrutura de tabelas	8
5.2	Reexecucao e controle de duplicidade	8
6	Indicadores e dashboard	9
6.1	Indicadores calculados	9
6.2	Dashboard	9
7	Validacao dos resultados	12
7.1	Execucao do workflow completo	12
7.2	Indicadores gerais obtidos	12
7.3	Conferencia de contagens	13
8	Conclusao	14
8.1	Principal resultado	14
8.2	Principais decisoes tecnicas	14
8.3	Aprendizado	14
9	Equipe	15



Contexto, objetivo e problema

1.1 Contexto academico

O trabalho final do Modulo 6 pede uma solucao pratica de ETL com Apache Hop, partindo de um dataset publico, com tratamento de dados dentro da pipeline, persistencia em banco relacional, orquestracao por workflow, indicadores e um dashboard.

1.2 Objetivo geral

Demonstrar, de forma pratica, o uso do Apache Hop para transformar dados brutos de qualidade do ar em informacao estruturada, apoiando a analise de periodos com piores condicoes ambientais.

1.3 Dataset utilizado

Dataset	Air Quality
Fonte	UCI Machine Learning Repository, https://archive.ics.uci.edu/dataset/360/air+quality
Origem dos dados	Estacao de monitoramento em uma cidade italiana (De Vito et al.)
Periodo	Marco de 2004 a fevereiro de 2005
Volume	9357 leituras horarias, 15 variaveis



1.4 Problema principal

Em quais periodos ocorreram as piores condicoes de qualidade do ar registradas, e quais variaveis ambientais (temperatura e umidade) estavam associadas a esses periodos? O ranking dos dez dias com maior media de CO, cruzado com a media de NO2 e o percentual de horas em condicao critica, responde diretamente a essa pergunta.



Arquitetura da solucao

2.1 Visao geral

```
Fonte de dados (CSV publico, UCI Air Quality)
|
Pipeline de ingestao e tratamento (pl_01_ingestao_tratamento.hpl)
|
Regras de classificacao (nivel de CO, nivel de NO2, turno do dia)
|
Banco de dados PostgreSQL (leituras_qualidade_ar, leituras_rejeitadas)
|
Pipeline de consolidacao (pl_02_consolidacao_indicadores.hpl)
|
Indicadores (resumo_diario_qualidade_ar, resumo_mensal_qualidade_ar)
|
Dashboard (dashboard/index.html)
```

As duas pipelines sao orquestradas pelo workflow `wf_orquestracao_qualidade_ar.hwf`: a consolidacao so e executada apos o sucesso da ingestao.

2.2 Tecnologias utilizadas

- **Apache Hop 2.18**: pipelines, workflow e metadados de conexao.
- **PostgreSQL 16**: banco de dados relacional, em container Docker.
- **Docker Compose**: subida do banco de dados local.
- **Chart.js**, vendorizado localmente: graficos do dashboard.
- **Python 3 e psql**: exportacao dos indicadores para o dashboard.



Pipelines Apache Hop

3.1 pl_01_ingestao_tratamento

Etapa	Transformacao	O que faz
Ingestao	CSV Input	Le data/raw/AirQualityUCI.csv (separador ;, decimal ,)
Qualidade	Filter Rows	Remove as linhas vazias do final do export do dataset
Tratamento	Formula	Combina data e hora originais em um texto unico
Tratamento	Null If	Converte o sentinela -200 em nulo, em 13 campos numericos
Tratamento	Select Values	Renomeia os campos tratados e remove os campos auxiliares
Tratamento	Select Values	Converte o texto de data e hora para o tipo Data
Enriquecimento	Calculator	Deriva ano, mes, dia, hora, dia da semana e a data de referencia
Enriquecimento	Value Mapper	Converte o numero do dia da semana no nome por extenso
Enriquecimento	Number Range	Classifica a hora em turno do dia
Enriquecimento	Number Range	Classifica o nivel de CO
Enriquecimento	Number Range	Classifica o nivel de NO2
Regra de negocio	Janino	Calcula se a leitura e valida e se a condicao e critica
Qualidade	Filter Rows	Separa leituras validas das leituras sem poluente de referencia



Etapa	Transformacao	O que faz
Banco de dados	Insert/Update	Grava as leituras validas em leituras_qualidade_ar
Banco de dados	Table Output	Grava as leituras rejeitadas em leituras_rejeitadas

Evidencia nao encontrada nesta compilacao

E04-pipeline-ingestao-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catalogo.

Figura 3.1: Canvas de pl_01_ingestao_tratamento no Hop Designer. Situacao atual: pendente de captura pela equipe.

3.2 pl_02_consolidacao_indicadores

Etapa	Transformacao	O que faz
Consolidacao dia- ria	Table Input	Agrega leituras_qualidade_ar por data
Banco de dados	Insert/Update	Grava o resumo em resumo_diario_qualidade_ar
Consolidacao men- sal	Table Input	Agrega leituras_qualidade_ar por ano e mes
Banco de dados	Insert/Update	Grava o resumo em resumo_mensal_qualidade_ar



Evidencia nao encontrada nesta compilacao

E05-pipeline-consolidacao-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catalogo.

Figura 3.2: Canvas de pl_02_consolidacao_indicadores no Hop Designer. Situacao atual: pendente de captura pela equipe.

3.3 Workflow de orquestracao

START -> Ingestao e tratamento -> Consolidacao de indicadores -> Processo concluido

O segundo hop so e seguido se a pipeline de ingestao terminar com sucesso.

Evidencia nao encontrada nesta compilacao

E06-workflow-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catalogo.

Figura 3.3: Canvas de wf_orquestracao_qualidade_ar no Hop Designer. Situacao atual: pendente de captura pela equipe.



Tratamento de dados

4.1 Valor sentinela -200

O dataset original usa -200 para indicar ausencia de leitura em qualquer sensor. O passo Null If converte esse valor em nulo antes de qualquer calculo, evitando que ele distorca medias e indicadores.

4.2 Linhas vazias do export

O arquivo termina com 114 linhas totalmente vazias, um artefato do processo de exportacao do dataset. Essas linhas sao descartadas logo apos a leitura do CSV, antes de qualquer outro tratamento.

4.3 Separacao de leituras invalidas

Uma leitura e considerada invalida quando os tres poluentes de referencia (CO, NOx e NO2) estao todos ausentes. Essas leituras sao gravadas em `leituras_rejeitadas`, com o motivo da rejeicao, em vez de entrarem no calculo dos indicadores.

4.4 Classificacao analitica

As faixas de BOM, MODERADO e CRITICO para CO e NO2 sao uma classificacao analitica definida para este projeto, calculada a partir dos percentis do proprio dataset (a faixa CRITICO representa aproximadamente o decimo mais alto de cada poluente). Nao ha referencia a uma norma regulatoria externa.



Banco de dados

5.1 Estrutura de tabelas

Tabela / visao	Finalidade
<code>leituras_qualidade_ar</code>	Dados tratados e detalhados, uma linha por leitura horaria valida
<code>leituras_rejeitadas</code>	Leituras sem nenhum poluente de referencia
<code>resumo_diario_qualidade_ar</code>	Indicadores agregados por dia
<code>resumo_mensal_qualidade_ar</code>	Indicadores agregados por mes
<code>vw_indicadores_gerais</code>	Indicadores gerais do periodo, usados pelo dashboard
<code>vw_ranking_piores_dias</code>	Os 10 dias de piores condicoes

O detalhamento completo das colunas esta em `docs/contrato-banco.md` no repositorio.

5.2 Reexecucao e controle de duplicidade

Pergunta obrigatoria do trabalho final

Se o pipeline for executado novamente com a mesma fonte de dados, o que acontece? A tabela `leituras_qualidade_ar` tem restricao `UNIQUE` em `data_hora`, e a carga usa `Insert/Update`: registros existentes sao atualizados, nenhuma linha e duplicada. As tabelas de resumo seguem a mesma logica, com chave em `data_referencia` e em `(ano, mes)`. A tabela de rejeitados e truncada e recarregada por completo a cada execucao, pois funciona como um log da ultima carga.

Esse comportamento foi validado executando o workflow duas vezes seguidas sobre o mesmo arquivo fonte: a contagem de linhas em `leituras_qualidade_ar` permaneceu em 8131 nas duas execucoes.



Indicadores e dashboard

6.1 Indicadores calculados

- Total de leituras tratadas e rejeitadas.
- Percentual de horas em condicao critica.
- CO e NO2 medios e maximos do periodo.
- Evolucao mensal de CO e de NO2.
- Distribuicao das leituras por nivel (BOM, MODERADO, CRITICO).
- Leituras por turno do dia.
- Ranking dos dez dias com piores condicoes.

6.2 Dashboard

O dashboard e uma pagina HTML estatica que le os indicadores exportados do PostgreSQL em formato JSON pelo script `scripts/exportar_dashboard.sh`.



Figura 6.1: Dashboard AeroTrack, cartoes de indicadores e graficos de evolucao mensal e classificacao. Situacao atual: disponivel.



Ranking dos 10 dias com piores condicoes				
Dias ordenados pela maior media diaria de CO, com media de NO2 e percentual de horas em condicao critica.				
DATA	CO MEDIO	NO2 MEDIO	HORAS CRITICAS	% HORAS CRITICAS
19/10/2004	5.65	139.75	6	75%
23/12/2004	5.32	166.52	17	70.83%
22/11/2004	5.06	163	15	62.5%
25/11/2004	4.64	159.74	13	54.17%
15/12/2004	4.43	162.96	13	54.17%
01/11/2004	4.33	102.22	11	45.83%
14/04/2004	4.19	130.53	5	33.33%
06/10/2004	4.19	98.38	4	50%
10/02/2005	4.16	223.35	16	66.67%
22/12/2004	4.06	172.09	10	41.67%

AeroTrack · Projeto academico · Capacitacao em IA e Transformacao Digital · Modulo 6 (Apache Hop)

Figura 6.2: Ranking dos dez dias com piores condicoes registradas. Situacao atual: disponivel.



Validacao dos resultados

7.1 Execucao do workflow completo

```
2026/08/17 - wf_orquestracao_qualidade_ar - Starting action [Ingestao e tratamento]
2026/08/17 - Gravar leitura rejeitada.0 - Finished processing (I=0, O=1226, R=1226, W=1226, U=0, E=0)
2026/08/17 - Gravar leitura tratada.0 - Finished processing (I=8131, O=8131, R=8131, W=8131, U=0, E=0)
2026/08/17 - wf_orquestracao_qualidade_ar - Finished action [Ingestao e tratamento] (result=[true])
2026/08/17 - wf_orquestracao_qualidade_ar - Starting action [Consolidacao de indicadores]
2026/08/17 - Gravar resumo diario.0 - Finished processing (I=363, O=363, R=363, W=363, U=0, E=0)
2026/08/17 - Gravar resumo mensal.0 - Finished processing (I=14, O=14, R=14, W=14, U=0, E=0)
2026/08/17 - wf_orquestracao_qualidade_ar - Finished action [Consolidacao de indicadores] (result=[true])
2026/08/17 - wf_orquestracao_qualidade_ar - Workflow execution finished
```

O log completo esta em docs/evidencias/logs/execucao-workflow-completo.log.

7.2 Indicadores gerais obtidos

Indicador	Valor
Total de leituras tratadas	8131
Total de leituras rejeitadas	1226
Percentual de horas em condicao critica	13,11%
CO medio (maximo)	2,15 mg/m3 (11,90 mg/m3)
NO2 medio (maximo)	113,09 ug/m3 (340,00 ug/m3)
Temperatura media	17,97 graus Celsius
Umidade relativa media	48,95%
Dias consolidados	363
Meses consolidados	14



7.3 Conferencia de contagens

A soma de leituras validas (8131) e rejeitadas (1226) confere com o total de linhas de dados apos a remocao das 114 linhas vazias do export (9357 linhas originais de dados). O ranking dos piores dias mostra media de NO2 e percentual de horas criticas elevados nas mesmas datas de maior media de CO, o que e coerente com o comportamento esperado de poluentes urbanos.



Conclusao

8.1 Principal resultado

O AeroTrack demonstra o ciclo completo de ETL do trabalho final: leitura de um dataset publico, tratamento real dentro do Apache Hop (nulos, linhas invalidas, conversao de tipos, classificacao), persistencia em banco relacional reexecutavel sem duplicidade, orquestracao por workflow e indicadores apresentados em um dashboard.

8.2 Principais decisoes tecnicas

- Combinar ingestao, tratamento, enriquecimento e carga em uma unica pipeline (p1_01), e a consolidacao em outra (p1_02), o que manteve o projeto com duas pipelines coerentes em vez de varias pipelines pequenas.
- Definir a classificacao de CO e NO2 a partir dos percentis reais do dataset, em vez de valores arbitrarios, para que o indicador de horas criticas fosse informativo.
- Usar Insert/Update com chave de negocio em todas as tabelas para que o processo seja seguro de reexecutar.

8.3 Aprendizado

A etapa mais trabalhosa nao foi desenhar o fluxo, e sim garantir que cada transformacao gravasse exatamente os campos esperados, principalmente na combinacao entre selecao de campos, conversao de tipos e a gravacao da chave no Insert/Update. Cada ajuste foi validado executando a pipeline real contra o banco de dados, nao apenas revisando a configuracao visualmente.



Equipe

Integrante	Git Hub	Frente
Juliana Ballin Lima	@JulianaBallin	Estrutura do projeto Hop, pipelines, banco de dados, workflow, dashboard e documentacao
Allef Oliveira Ramos	@allef-oliveira	Regras de classificacao e revisao dos indicadores
Fernanda de Oliveira da Costa	@nanda-costa	Validacao do tratamento de dados e do contrato do banco
Pedro Henrique Oliveira Dias	@pedroddias-oss	Testes de reexecucao, evidencias e apresentacao