



AeroTrack
Air quality monitoring with Apache Hop

RELATÓRIO DE DESENVOLVIMENTO

Monitoramento de Qualidade do Ar com Apache Hop

Trabalho Final | Módulo 6 | Apache Hop



Equipe AeroTrack

Allef Oliveira Ramos	@allef-oliveira
Fernanda de Oliveira da Costa	@nanda-costa
Juliana Ballin Lima	@JulianaBallin
Pedro Henrique Oliveira Dias	@pedroddias-oss

Manaus | 2026

Capacitação em IA e Transformação Digital



Identificação do documento

Projeto	AeroTrack
Documento	Relatório de Desenvolvimento
Curso	Capacitação em IA e Transformação Digital
Módulo	Módulo 6 de Apache Hop
Projeto sugerido	Projeto 4, Monitoramento de Qualidade do Ar
Repositorio	https://github.com/JulianaBallin/AeroTrack
Branch de desenvolvimento	develop
Versão	1.0
Situação	Pipelines, workflow, banco de dados e dashboard validados de ponta a ponta

Controle de revisão

Este documento registra o problema, a arquitetura, as pipelines, o tratamento de dados, o banco de dados, os indicadores, o dashboard e a validação dos resultados do AeroTrack. Todas as execuções descritas foram realizadas contra o banco de dados real, via linha de comando do Apache Hop.



Resumo executivo

O AeroTrack é uma solução de integração de dados construída com Apache Hop para o Projeto 4 sugerido no trabalho final do Módulo 6: monitoramento de qualidade do ar. O dataset público Air Quality (UCI Machine Learning Repository) é lido, tratado, classificado e persistido em um banco de dados PostgreSQL, com indicadores consolidados e apresentados em um dashboard.

Resultado técnico atual

- Duas pipelines Apache Hop (ingestão/tratamento e consolidação) e um workflow de orquestração, executados de ponta a ponta sem erros.
- 9357 leituras horárias processadas: 8131 gravadas como válidas e 1226 separadas por não terem nenhum poluente de referência.
- Banco de dados PostgreSQL com quatro tabelas e duas visões, reexecutável sem duplicidade por chave única e Insert/Update.
- Indicadores diários (363 dias) e mensais (14 meses) consolidados.
- Dashboard estático com sete indicadores, quatro gráficos e o ranking dos dez piores dias.



Sumário

Identificação do documento	i
Resumo executivo	ii
1 Contexto, objetivo e problema	1
1.1 Contexto acadêmico	1
1.2 Objetivo geral	1
1.3 Dataset utilizado	1
1.4 Problema principal	2
2 Arquitetura da solução	3
2.1 Visão geral	3
2.2 Tecnologias utilizadas	3
3 Pipelines Apache Hop	4
3.1 pl_01_ingestion_treatment	4
3.2 pl_02_indicator_consolidation	5
3.3 Workflow de orquestração	6
4 Tratamento de dados	7
4.1 Valor sentinela -200	7
4.2 Linhas vazias do export	7
4.3 Separação de leituras inválidas	7
4.4 Classificação analítica	7
5 Banco de dados	8



5.1	Estrutura de tabelas	8
5.2	Reexecução e controle de duplicidade	9
6	Indicadores e dashboard	10
6.1	Indicadores calculados	10
6.2	Dashboard	10
7	Validação dos resultados	12
7.1	Execução do workflow completo	12
7.2	Indicadores gerais obtidos	12
7.3	Conferência de contagens	13
8	Conclusão	14
8.1	Principal resultado	14
8.2	Principais decisões técnicas	14
8.3	Aprendizado	14
9	Manual de replicação	15
9.1	Pré-requisitos	15
9.2	Passo a passo	15
9.3	Solução de problemas	16
10	Equipe	17



Contexto, objetivo e problema

1.1 Contexto acadêmico

O trabalho final do Módulo 6 pede uma solução prática de ETL com Apache Hop, partindo de um dataset público, com tratamento de dados dentro da pipeline, persistência em banco relacional, orquestração por workflow, indicadores e um dashboard.

1.2 Objetivo geral

Demonstrar, de forma prática, o uso do Apache Hop para transformar dados brutos de qualidade do ar em informação estruturada, apoiando a análise de períodos com piores condições ambientais.

1.3 Dataset utilizado

Dataset	Air Quality
Fonte	UCI Machine Learning Repository, https://archive.ics.uci.edu/dataset/360/air+quality
Origem dos dados	Estação de monitoramento em uma cidade italiana (De Vito et al.)
Período	Marco de 2004 a fevereiro de 2005
Volume	9357 leituras horárias, 15 variáveis



1.4 Problema principal

Em quais períodos ocorreram as piores condições de qualidade do ar registradas, e quais variáveis ambientais (temperatura e umidade) estavam associadas a esses períodos? O ranking dos dez dias com maior média de CO, cruzado com a média de NO2 e o percentual de horas em condição crítica, responde diretamente a essa pergunta.



Arquitetura da solução

2.1 Visão geral



Figura 2.1: Fluxo de ponta a ponta do AeroTrack: do dataset público ao dashboard.

As duas pipelines são orquestradas pelo workflow `wf_air_quality_orchestration.hwf`: a consolidação só é executada após o sucesso da ingestão.

2.2 Tecnologias utilizadas

- **Apache Hop 2.18**: pipelines, workflow e metadados de conexão.
- **PostgreSQL 16**: banco de dados relacional, em container Docker.
- **Docker Compose**: subida do banco de dados local.
- **Chart.js**, vendorizado localmente: gráficos do dashboard.
- **Python 3 e psql**: exportação dos indicadores para o dashboard.



Pipelines Apache Hop

3.1 pl_01_ingestion_treatment

Etapa	Transformação	O que faz
Ingestão	CSV Input	Le <code>data/raw/AirQualityUCI.csv</code> (separador ;, decimal ,)
Qualidade	Filter Rows	Remove as linhas vazias do final do export do dataset
Tratamento	Formula	Combina data e hora originais em um texto único
Tratamento	Null If	Converte o sentinela -200 em nulo, em 13 campos numéricos
Tratamento	Select Values	Renomeia os campos tratados e remove os campos auxiliares
Tratamento	Select Values	Converte o texto de data e hora para o tipo Data
Enriquecimento	Calculator	Deriva ano, mes, dia, hora, dia da semana e a data de referência
Enriquecimento	Value Mapper	Converte o número do dia da semana no nome por extenso
Enriquecimento	Number Range	Classifica a hora em turno do dia
Enriquecimento	Number Range	Classifica o nível de CO
Enriquecimento	Number Range	Classifica o nível de NO2
Regra de negócio	Janino	Calcula se a leitura é válida e se a condição é crítica
Qualidade	Filter Rows	Separa leituras válidas das leituras sem poluente de referência
Banco de dados	Insert/Update	Grava as leituras válidas em <code>leituras_qualidade_ar</code>



Etapa	Transformação	O que faz
Banco de dados	Table Output	Grava as leituras rejeitadas em leituras_rejeitadas

Evidência não encontrada nesta compilação

E04-pipeline-ingestion-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catálogo.

Figura 3.1: Canvas de pl_01_ingestion_treatment no Hop Designer. Situação atual: pendente de captura pela equipe.

3.2 pl_02_indicator_consolidation

Etapa	Transformação	O que faz
Consolidação diária	Table Input	Agrega leituras_qualidade_ar por data
Banco de dados	Insert/Update	Grava o resumo em resumo_diario_qualidade_ar
Consolidação mensal	Table Input	Agrega leituras_qualidade_ar por ano e mes
Banco de dados	Insert/Update	Grava o resumo em resumo_mensal_qualidade_ar



Evidência não encontrada nesta compilação

E05-pipeline-consolidation-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catálogo.

Figura 3.2: Canvas de pl_02_indicator_consolidation no Hop Designer. Situação atual: pendente de captura pela equipe.

3.3 Workflow de orquestração

```
START -> Ingestion and treatment -> Indicator consolidation -> Process completed
```

O segundo hop só é seguido se a pipeline de ingestão terminar com sucesso.

Evidência não encontrada nesta compilação

E06-workflow-canvas.png

Adicione a imagem em docs/evidencias/capturas/ conforme o catálogo.

Figura 3.3: Canvas de wf_air_quality_orchestration no Hop Designer. Situação atual: pendente de captura pela equipe.



Tratamento de dados

4.1 Valor sentinela -200

O dataset original usa -200 para indicar ausencia de leitura em qualquer sensor. O passo Null If converte esse valor em nulo antes de qualquer calculo, evitando que ele distorça médias e indicadores.

4.2 Linhas vazias do export

O arquivo termina com 114 linhas totalmente vazias, um artefato do processo de exportação do dataset. Essas linhas são descartadas logo após a leitura do CSV, antes de qualquer outro tratamento.

4.3 Separação de leituras inválidas

Uma leitura é considerada inválida quando os três poluentes de referência (CO, NOx e NO2) estão todos ausentes. Essas leituras são gravadas em `leituras_rejeitadas`, com o motivo da rejeicao, em vez de entrarem no calculo dos indicadores.

4.4 Classificação analítica

As faixas de BOM, MODERADO e CRÍTICO para CO e NO2 são uma classificação analítica definida para este projeto, calculada a partir dos percentis do próprio dataset (a faixa CRÍTICO representa aproximadamente o décimo mais alto de cada poluente). Não há referência a uma norma regulatória externa.



Banco de dados

5.1 Estrutura de tabelas

Tabela / visão	Finalidade
<code>leituras_qualidade_ar</code>	Dados tratados e detalhados, uma linha por leitura horária válida
<code>leituras_rejeitadas</code>	Leituras sem nenhum poluente de referência
<code>resumo_diario_qualidade_ar</code>	Indicadores agregados por dia
<code>resumo_mensal_qualidade_ar</code>	Indicadores agregados por mês
<code>vw_indicadores_gerais</code>	Indicadores gerais do período, usados pelo dashboard
<code>vw_ranking_piores_dias</code>	Os 10 dias de piores condições

O detalhamento completo das colunas está em `docs/pt/contrato-banco.md` no repositório.

```
aerotrack-hop-postgres - psql

aerotrack@postgres:~$ psql -U aerotrack -d aerotrack -c "\dt"

          List of relations
Schema |          Name          | Type | Owner
-----+-----+-----+-----
public | leituras_qualidade_ar  | table | aerotrack
public | leituras_rejeitadas    | table | aerotrack
public | resumo_diario_qualidade_ar | table | aerotrack
public | resumo_mensal_qualidade_ar | table | aerotrack
(4 rows)

aerotrack@postgres:~$ psql -U aerotrack -d aerotrack -c "\dv"

          List of relations
Schema |          Name          | Type | Owner
-----+-----+-----+-----
public | vw_indicadores_gerais  | view  | aerotrack
public | vw_ranking_piores_dias | view  | aerotrack
(2 rows)
```

Figura 5.1: Tabelas e visões criadas no PostgreSQL (`psql`, `\dt` e `\dv`). Situação atual: disponível.



```
aerotrack-hop-postgres - psql

aerotrack@postgres:~$ psql -U aerotrack -d aerotrack -c \
"SELECT id, data_hora, dia_semana, turno, co_gt, no2_gt, co_nivel, no2_nivel, condicao_critica
FROM leituras_qualidade_ar ORDER BY data_hora LIMIT 8;"

 id | data_hora | dia_semana | turno | co_gt | no2_gt | co_nivel | no2_nivel | condicao_critica
-----+-----+-----+-----+-----+-----+-----+-----+-----
48788 | 2004-03-10 18:00:00 | QUARTA-FEIRA | NOITE | 2.60 | 113.00 | MODERADO | MODERADO | NAO
48789 | 2004-03-10 19:00:00 | QUARTA-FEIRA | NOITE | 2.00 | 92.00 | MODERADO | MODERADO | NAO
48790 | 2004-03-10 20:00:00 | QUARTA-FEIRA | NOITE | 2.20 | 114.00 | MODERADO | MODERADO | NAO
48791 | 2004-03-10 21:00:00 | QUARTA-FEIRA | NOITE | 2.20 | 122.00 | MODERADO | MODERADO | NAO
48792 | 2004-03-10 22:00:00 | QUARTA-FEIRA | NOITE | 1.60 | 116.00 | BOM | MODERADO | NAO
48793 | 2004-03-10 23:00:00 | QUARTA-FEIRA | NOITE | 1.20 | 96.00 | BOM | MODERADO | NAO
48794 | 2004-03-11 00:00:00 | QUINTA-FEIRA | MADRUGADA | 1.20 | 77.00 | BOM | BOM | NAO
48795 | 2004-03-11 01:00:00 | QUINTA-FEIRA | MADRUGADA | 1.00 | 76.00 | BOM | BOM | NAO
(8 rows)
```

Figura 5.2: Amostra real de `leituras_qualidade_ar`, com a hora 23h já classificada corretamente como NOITE após a correção descrita no registro de ajustes. Situação atual: disponível.

5.2 Reexecução e controle de duplicidade

Pergunta obrigatória do trabalho final

Se o pipeline for executado novamente com a mesma fonte de dados, o que acontece? A tabela `leituras_qualidade_ar` tem restrição `UNIQUE` em `data_hora`, e a carga usa `Insert/Update`: registros existentes são atualizados, nenhuma linha é duplicada. As tabelas de resumo seguem a mesma lógica, com chave em `data_referencia` e em `(ano, mes)`. A tabela de rejeitados é truncada e recarregada por completo a cada execução, pois funciona como um log da última carga.

Esse comportamento foi validado executando o workflow duas vezes seguidas sobre o mesmo arquivo fonte: a contagem de linhas em `leituras_qualidade_ar` permaneceu em 8131 nas duas execuções.



Indicadores e dashboard

6.1 Indicadores calculados

- Total de leituras tratadas e rejeitadas.
- Percentual de horas em condição crítica.
- CO e NO2 médios e máximos do período.
- Evolução mensal de CO e de NO2.
- Distribuição das leituras por nível (BOM, MODERADO, CRÍTICO).
- Leituras por turno do dia.
- Ranking dos dez dias com piores condições.

6.2 Dashboard

O dashboard é uma página HTML estática que lê os indicadores exportados do PostgreSQL em formato JSON pelo script `scripts/export_dashboard.sh`.



Figura 6.1: Dashboard AeroTrack, cartões de indicadores e gráficos de evolução mensal e classificação. Situação atual: disponível.

Ranking of the 10 worst days				
Days sorted by the highest daily average CO, with average NO2 and percentage of hours in critical condition.				
DATE	AVG. CO	AVG. NO2	CRITICAL HOURS	% CRITICAL HOURS
10/19/2004	5.65	139.75	6	75%
12/23/2004	5.32	166.52	17	70.83%
11/22/2004	5.06	163	15	62.5%
11/25/2004	4.64	159.74	13	54.17%
12/15/2004	4.43	162.96	13	54.17%
11/1/2004	4.33	102.22	11	45.83%
4/14/2004	4.19	130.53	5	33.33%
10/6/2004	4.19	98.38	4	50%
2/10/2005	4.16	223.35	16	66.67%
12/22/2004	4.06	172.09	10	41.67%

Figura 6.2: Ranking dos dez dias com piores condições registradas. Situação atual: disponível.



Validação dos resultados

7.1 Execução do workflow completo

```
2026/08/17 - wf_air_quality_orchestration - Starting action [Ingestion and treatment]
2026/08/17 - Write rejected reading.0 - Finished processing (I=0, O=1226, R=1226, W=1226, U=0, E=0)
2026/08/17 - Write treated reading.0 - Finished processing (I=8131, O=0, R=8131, W=8131, U=0, E=0)
2026/08/17 - wf_air_quality_orchestration - Finished action [Ingestion and treatment] (result=[true])
2026/08/17 - wf_air_quality_orchestration - Starting action [Indicator consolidation]
2026/08/17 - Write daily summary.0 - Finished processing (I=363, O=0, R=363, W=363, U=0, E=0)
2026/08/17 - Write monthly summary.0 - Finished processing (I=14, O=0, R=14, W=14, U=0, E=0)
2026/08/17 - wf_air_quality_orchestration - Finished action [Indicator consolidation] (result=[true])
2026/08/17 - wf_air_quality_orchestration - Workflow execution finished
```

O log completo está em docs/evidencias/logs/execução-workflow-completo.log.

7.2 Indicadores gerais obtidos

Indicador	Valor
Total de leituras tratadas	8131
Total de leituras rejeitadas	1226
Percentual de horas em condição crítica	13,11%
CO médio (máximo)	2,15 mg/m3 (11,90 mg/m3)
NO2 médio (máximo)	113,09 ug/m3 (340,00 ug/m3)
Temperatura média	17,97 graus Celsius
Umidade relativa média	48,95%
Dias consolidados	363
Meses consolidados	14



7.3 Conferência de contagens

A soma de leituras válidas (8131) e rejeitadas (1226) confere com o total de linhas de dados após a remoção das 114 linhas vazias do export (9357 linhas originais de dados). O ranking dos piores dias mostra média de NO₂ e percentual de horas críticas elevados nas mesmas datas de maior média de CO, o que é coerente com o comportamento esperado de poluentes urbanos.



Conclusão

8.1 Principal resultado

O AeroTrack demonstra o ciclo completo de ETL do trabalho final: leitura de um dataset público, tratamento real dentro do Apache Hop (nulos, linhas inválidas, conversão de tipos, classificação), persistência em banco relacional reexecutável sem duplicidade, orquestração por workflow e indicadores apresentados em um dashboard.

8.2 Principais decisões técnicas

- Combinar ingestão, tratamento, enriquecimento e carga em uma única pipeline (p1_01), e a consolidação em outra (p1_02), o que manteve o projeto com duas pipelines coerentes em vez de várias pipelines pequenas.
- Definir a classificação de CO e NO2 a partir dos percentis reais do dataset, em vez de valores arbitrários, para que o indicador de horas críticas fosse informativo.
- Usar Insert/Update com chave de negócio em todas as tabelas para que o processo seja seguro de reexecutar.

8.3 Aprendizado

A etapa mais trabalhosa não foi desenhar o fluxo, e sim garantir que cada transformação gravasse exatamente os campos esperados, principalmente na combinação entre seleção de campos, conversão de tipos e a gravação da chave no Insert/Update. Cada ajuste foi validado executando a pipeline real contra o banco de dados, não apenas revisando a configuração visualmente.



9

Manual de replicação

Este capítulo descreve como reproduzir o AeroTrack do zero em uma máquina limpa. O mesmo conteúdo, sempre atualizado, está em `docs/manual-replicacao.md` no repositório.

9.1 Pré-requisitos

Ferramenta	Versão mínima	Uso
Docker Engine	24	Executar o PostgreSQL local
Docker Compose	2.20	Orquestrar o container do banco
Java (JDK)	21	Executar o Apache Hop
Apache Hop	2.18	Executar as pipelines e o workflow
Python	3.10	Exportar os indicadores para o dashboard

9.2 Passo a passo

1. Clonar o repositório

```
git clone https://github.com/JulianaBallin/AeroTrack.git
cd AeroTrack
```

2. Subir o banco de dados

```
cd database && docker compose up -d
```

3. Registrar o projeto no Apache Hop (uma vez por máquina)

```
hop-conf.sh -pc -p aerotrack -ph "$(pwd)/hop" -pf project-config.json -pkf
```



4. Executar o processo completo

```
hop-run.sh -j aerotrack \  
-f hop/workflows/wf_air_quality_orchestration.hwf -r local -l Basic
```

5. Gerar e abrir o dashboard

```
scripts/export_dashboard.sh  
cd dashboard && python3 -m http.server 8000
```

Script único

Os passos 2, 4 e 5 estão automatizados em `scripts/replicate.sh`. O script verifica os pré-requisitos, sobe o banco, registra o projeto no Hop se necessário, executa o workflow e exporta o dashboard.

9.3 Solução de problemas

Sintoma	Solução
<code>hop-run.sh</code> não encontra o projeto	Repita o passo de registro do projeto
Erro de conexão com o PostgreSQL	Aguarde o container ficar healthy
Porta 5434 ocupada	Ajuste a porta em <code>database/docker-compose.yml</code> e no arquivo de conexão do Hop
Dashboard em branco no navegador	Sirva a pasta com <code>python3 -m http.server</code> , não abra o arquivo diretamente



Equipe

Integrante	GitHub	Frente
Juliana Ballin Lima	@JulianaBallin	Estrutura do projeto Hop, pipelines, banco de dados, workflow, dashboard e documentação
Allef Oliveira Ramos	@allef-oliveira	Regras de classificação e revisão dos indicadores
Fernanda de Oliveira da Costa	@nanda-costa	Validação do tratamento de dados e do contrato do banco
Pedro Henrique Oliveira Dias	@pedroddias-oss	Testes de reexecução, evidências e apresentação